



UNIVERSIDAD NACIONAL  
AUTÓNOMA DE MÉXICO  
FACULTAD DE CIENCIAS

PROYECTO FINAL:  
Abandono de Clientes

Equipo

García Meza Iván  
Novoa Hernández Moisés Fortino  
Roldán Navarro Andrés Manuel

ASIGNATURA

Análisis Multivariado  
Profesor: José A. Perusquía Cortés  
Ayudante: Aaron Mauricio Gómez Jiménez

Fecha: 2026-05

---

# Índice

|                                                          |           |
|----------------------------------------------------------|-----------|
| <b>Resumen</b>                                           | <b>3</b>  |
| <b>1. Introducción</b>                                   | <b>4</b>  |
| 1.1. DESCRIPCIÓN DE VARIABLES DATASET CHURN . . . . .    | 4         |
| <b>2. Análisis Descriptivo</b>                           | <b>5</b>  |
| 2.1. Matriz de covarianza . . . . .                      | 6         |
| 2.2. Correlación . . . . .                               | 8         |
| 2.3. Grafica de dispersión . . . . .                     | 10        |
| 2.4. Curvas de Andrews . . . . .                         | 10        |
| <b>3. Normalidad</b>                                     | <b>11</b> |
| 3.1. Normalidad Multivariada . . . . .                   | 11        |
| 3.2. Normalidad univariada . . . . .                     | 12        |
| <b>4. Análisis de Factores y Componentes principales</b> | <b>12</b> |
| 4.1. PCA . . . . .                                       | 13        |
| 4.2. Análisis de Factores . . . . .                      | 13        |
| <b>5. Análisis de Correspondencias</b>                   | <b>14</b> |
| <b>6. Modelos Predictivos</b>                            | <b>15</b> |
| 6.1. Clustering . . . . .                                | 16        |
| 6.2. Regresión Logística . . . . .                       | 19        |
| 6.3. k-Nearest Neighbors (kNN) . . . . .                 | 21        |
| 6.4. Comparación de lo Modelos . . . . .                 | 22        |

---

## Resumen

El presente proyecto se desarrolla con la intención de acertar y aplicar los conocimientos adquiridos durante el curso de **Análisis Multivariado**.

A partir de la base de datos proporcionada por el profesor correspondiente a **El Sector de Telecomunicaciones** y enfocada en el análisis de abandono de clientes(Churn), para la construcción de un modelo predictivo.

La metodología contempla la división del conjunto de datos en 2 partes: un 80 % destinado para el análisis y entrenamiento del modelo y un 20 % reservado para la validación, Evitando un sobre-ajuste del modelo.

---

# 1. Introducción

A partir de la base de datos de clientes, este proyecto busca aplicar los temas del curso para identificar patrones de comportamiento y variables asociadas al abandono. El propósito es desarrollar modelos predictivos que permitan anticipar la cancelación de servicios.

## 1.1. DESCRIPCIÓN DE VARIABLES DATASET CHURN

Primero es necesario conocer la base de datos, así como la variables que la constituyen. por eso mismo a continuación una breve descripción de la base de datos y explicación de la base de batos:

- — Información general —
  - State: Estado donde vive el cliente
  - Account length: Días que el cliente ha tenido la cuenta
  - Area code: Código de área telefónica
- — Planes contratados —
  - International plan: Tiene plan internacional (Yes/No)
  - Voice mail plan: Tiene buzón de voz (Yes/No)
  - Number vmail messages: Número de mensajes de voz
- — Uso durante el día —
  - Total day minutes: Minutos de llamadas durante el día
  - Total day calls: Número de llamadas durante el día
  - Total day charge: Costo de llamadas del día
- — Uso durante la tarde —
  - Total eve minutes: Minutos de llamadas en la tarde
  - Total eve calls: Número de llamadas en la tarde
  - Total eve charge: Costo de llamadas en la tarde
- — Uso durante la noche —
  - Total night minutes: Minutos de llamadas en la noche

- 
- Total night calls: Número de llamadas en la noche
  - Total night charge: Costo de llamadas en la noche
  - — Uso internacional —
    - Total intl minutes: Minutos de llamadas internacionales
    - Total intl calls: Número de llamadas internacionales
    - Total intl charge: Costo de llamadas internacionales
  - — Atención al cliente —
    - Customer service calls: Número de llamadas al servicio al cliente
  - — Variable objetivo —
    - Churn: Indica si el cliente abandona la compañía (True/False)

## 2. Análisis Descriptivo

Al profundizar en la estructura de la base de datos, la cual tiene los datos de 2666 clientes, podemos notar que esta compuesta de de 20 variables, 15 variables numéricas y 5 categóricas.

Después de un análisis inicial podemos notar las siguientes observaciones:

- índice de abandono del 14.5 % aproximadamente
- un 10 % de los clientes tienen plan internacional
- Solo el 27.5 % de los clientes tienen Plan de buzón de voz
- un promedio 100.6 meses (8 años) en un rango de 1 a 243 meses
- 8 mensajes de voz promedio, con mediana de 0 mensajes (muchos clientes no lo usan) y un maximo de 50 mensajes.
- Minutos en el día: promedio 179 min, con un cargo de 30.5 USD
- Minutos Vespertinos: promedio 200.4 min; con un cargo de 17 USD
- Minutos Nocturnos: promedio 201.2 min, con un cargo de 2.76 USD
- Llamadas en el día: promedio = 100
- Llamadas vespertinas: promedio = 100

- 
- Llamadas nocturnas: promedio = 100
  - Llamadas internacionales: promedio= 4.25
  - llamadas a atención a clientes: promedio= 1.56 con un maximo de 9 llamadas

## 2.1. Matriz de covarianza

La tabla adjunta en el reporte representa la matriz de covarianzas entre las variables numéricas.

La matriz de covarianzas evidencia la estructura interna del comportamiento de los clientes en el servicio de telecomunicaciones. Se observan bloques de variables altamente relacionadas —minutos y llamadas en las franjas diurna, vespertina y nocturna— que reflejan patrones de uso consistentes y homogéneos. Estas relaciones indican que los clientes mantienen hábitos similares de comunicación a lo largo del día, lo que sugiere estabilidad en el consumo.

Por otro lado, las variables de uso internacional y atención al cliente presentan covarianzas bajas respecto al resto, lo que revela independencia en su comportamiento. El uso internacional parece responder a necesidades específicas de ciertos segmentos, mientras que las llamadas al servicio al cliente podrían estar asociadas a factores de insatisfacción o problemas técnicos más que al volumen de uso..

Finalmente, la duración de la cuenta muestra una relación moderada con las variables de consumo, lo que podría reflejar que los clientes con mayor antigüedad tienden a mantener patrones más estables. En conjunto, esta estructura sugiere que el análisis multivariado permitirá distinguir entre patrones rutinarios de uso y factores críticos de abandono, aportando una base sólida para la modelación del churn.

Tabla 1: Matriz de covarianzas

|      | AL      | VM     | TDM     | TDC    | TDCh   | TEM     | TEC    | TECh   | TNM     | TNC    | TNCh   | TIM   | TIC   | TICH  | CSC   |
|------|---------|--------|---------|--------|--------|---------|--------|--------|---------|--------|--------|-------|-------|-------|-------|
| AL   | 1565.31 | -1.61  | 6.11    | 30.73  | 1.04   | -32.10  | 14.80  | -2.73  | -18.07  | -18.44 | -0.81  | 1.25  | 1.71  | 0.34  | 0.13  |
| VM   |         | 185.29 | 14.04   | -2.62  | 2.39   | 7.91    | 1.41   | 0.67   | -0.15   | 2.15   | -0.01  | -0.16 | 0.90  | -0.04 | -0.34 |
| TDM  |         |        | 2938.76 | 18.18  | 499.59 | 11.04   | 9.90   | 0.94   | 37.14   | 15.85  | 1.67   | -1.67 | 0.76  | -0.45 | -1.74 |
| TDC  |         |        |         | 399.53 | 3.09   | -26.48  | 2.61   | -2.25  | 9.12    | -6.51  | 0.41   | 1.73  | 0.34  | 0.47  | -0.31 |
| TDCh |         |        |         |        | 84.93  | 1.88    | 1.68   | 0.16   | 6.32    | 2.69   | 0.28   | -0.28 | 0.13  | -0.08 | -0.30 |
| TEM  |         |        |         |        |        | 2596.06 | -7.86  | 220.66 | -34.71  | 8.92   | -1.57  | -0.98 | 0.27  | -0.27 | -0.88 |
| TEC  |         |        |         |        |        |         | 406.48 | -0.67  | -0.18   | 0.31   | -0.01  | 0.62  | 0.18  | 0.17  | 0.03  |
| TECh |         |        |         |        |        |         |        | 18.76  | -2.95   | 0.76   | -0.13  | -0.08 | 0.02  | -0.02 | -0.07 |
| TNM  |         |        |         |        |        |         |        |        | 2578.64 | 12.56  | 116.04 | -1.22 | -0.14 | -0.33 | 0.35  |
| TNC  |         |        |         |        |        |         |        |        |         | 377.08 | 0.56   | -1.27 | 0.92  | -0.34 | -0.14 |
| TNCh |         |        |         |        |        |         |        |        |         |        | 5.22   | -0.05 | -0.01 | -0.01 | 0.02  |
| TIM  |         |        |         |        |        |         |        |        |         |        |        | 7.77  | 0.26  | 2.10  | -0.01 |
| TIC  |         |        |         |        |        |         |        |        |         |        |        |       | 6.03  | 0.07  | -0.07 |
| TICH |         |        |         |        |        |         |        |        |         |        |        |       |       | 0.57  | 0.00  |
| CSC  |         |        |         |        |        |         |        |        |         |        |        |       |       |       | 1.72  |

**Abreviaturas:** AL = Account.length, VM = Number.vmail.messages, TDM = Total.day.messages, TDC = Total.day.minutes, TDCh = Total.day.charge, TEM = Total.eve.minutes, TEC = Total.eve.calls, TECh = Total.eve.charge, TNM = Total.night.minutes, TNC = Total.night.calls, TNCh = Total.night.charge, TIM = Total.intl.minutes, TIC = Total.intl.calls, TICH = Total.intl.charge, CSC = Customer.service.calls.

## 2.2. Correlación




Figura 1: Correlación entre las variables

Las correlaciones perfectas (1.0) confirman que las variables de minutos y cargos están linealmente relacionadas, lo que implica que una puede sustituir a la otra en los modelos para evitar redundancia.


El resto de las variables presentan correlaciones cercanas a 0, lo que indica no correlación entre ellas.

En general, el dataset tiene baja multicolinealidad, salvo en los pares minutos-cargo, lo cual es favorable para la construcción de modelos multivariados.

Las demás variables tienen correlaciones cercanas a 0, por lo que el PCA no encontrará estructuras lineales fuertes entre ellas. Esto implica que los primeros componentes explicarán poca varianza total y que el PCA no será muy efectivo para resumir el conjunto completo si se incluyen todas las variables sin depuración previa.

Al separar por churn obtenemos los siguientes graficos :

Matriz de Correlación – Clientes que No Cancelaron



Matriz de Correlación – Clientes que Cancelaron





Figura 2: Comparación de imágenes.

El análisis comparativo entre las matrices de correlación de clientes que no cancelaron y aquellos que cancelaron revela diferencias relevantes en la estructura de las relaciones entre las variables numéricas. En el grupo de clientes activos, las correlaciones son prácticamente nulas, salvo las relaciones perfectas entre variables dependientes (minutos y cargos), lo que evidencia un patrón de consumo estable y homogéneo. Este comportamiento sugiere que los usuarios que permanecen en la empresa mantienen hábitos regulares y no presentan interacciones significativas entre los distintos tipos de uso del servicio.

Por el contrario, en el grupo de clientes que cancelaron se observan correlaciones débiles pero más diversas, tanto positivas como negativas, especialmente entre las variables de uso y las llamadas al servicio al cliente. Este comportamiento indica una mayor dispersión en los patrones de consumo y podría reflejar situaciones de insatisfacción o problemas con el servicio. La variable *Customer.service.calls* destaca como un posible indicador de riesgo de abandono, al mostrar una relación inversa con el uso del servicio.

## 2.3. Grafica de dispersión




podemos observar en la dispersión de minutos en las franjas diurna, vespertina y nocturna, una tendencia a distribuirse de manera simétrica alrededor de la media. esto sugiere que el consumo no está concentrado en un solo periodo, sino que se reparte de manera equilibrada en la mayoría de los clientes.

La nube de puntos de mensajes de voz frente a otras variables revele una gran concentración en cero, con poca variabilidad. Indica que el buzón de voz no es un factor determinante en el abandono.

Aunque la correlación es baja, la dispersión muestra que los clientes con más llamadas al servicio al cliente tienden a agruparse en valores altos de Churn.

## 2.4. Curvas de Andrews

En la siguiente gráfica, aunque los grupos están muy solapados, podemos notar que el grupo de TRUE tiende a mostrar fluctuaciones más amplias, que sugiere que los clientes que abandonan presentan un comportamiento menos predecible.



### 3. Normalidad

Para verificar Normalidad realizamos 2 pruebas multivariada y 2 univariadas para cada variable, con el propósito de ver si en su conjuntos es Normal y comparar con las pruebas univariadas.

#### 3.1. Normalidad Multivariada

Realizamos 2 pruebas de normalidad Multivariada los resultados se muestran en la siguiente tabla.

| Prueba          | P-value | Resultado  |
|-----------------|---------|------------|
| Mardia Skewness | < 0.001 | Not normal |
| Mardia Kurtosis | 0.15    | Normal     |
| Henze-Zirkler   | < 0.001 | Not normal |

Tabla 2: Resultados de pruebas de normalidad multivariante

**Mardia Skewness** (< 0.001, Not normal): Indica que existe asimetría multivariada significativa. En otras palabras, las variables no se distribuyen de manera

simétrica

**Mardia Kurtosis** (0.15, Normal): El valor de p es mayor que 0.05, por lo que no se rechaza la normalidad en términos de curtosis. Esto implica que las colas de la distribución no son excesivamente pesadas ni concentradas.

**Henze–Zirkler** ( $< 0.001$ , Not normal): Este test, más robusto y general, confirma la no normalidad multivariada global del conjunto de datos.

Aunque la curtosis parece ajustarse a la normalidad, la asimetría y el resultado del test Henze–Zirkler muestran que el conjunto no cumple completamente con la normalidad multivariada.

### 3.2. Normalidad univariada

En la siguiente tabla se encuentra algunas pruebas de normalidad con su respectivo p-value para las variables:

Tabla 3: Resultados de las pruebas de normalidad Shapiro–Wilk y Anderson–Darling

| Variable               | Shapiro–Wilk |           | Anderson–Darling |           |
|------------------------|--------------|-----------|------------------|-----------|
|                        | p-value      | Resultado | p-value          | Resultado |
| Account.length         | 0.00889      | No normal | 0.586            | Normal    |
| Number.vmail.messages  | 0.00000      | No normal | $<0.001$         | No normal |
| Total.day.minutes      | 0.55622      | Normal    | 0.745            | Normal    |
| Total.day.calls        | 0.00014      | No normal | 0.095            | Normal    |
| Total.day.charge       | 0.55588      | Normal    | 0.744            | Normal    |
| Total.eve.minutes      | 0.73311      | Normal    | 0.503            | Normal    |
| Total.eve.calls        | 0.00794      | No normal | 0.173            | Normal    |
| Total.eve.charge       | 0.73015      | Normal    | 0.498            | Normal    |
| Total.night.minutes    | 0.47216      | Normal    | 0.746            | Normal    |
| Total.night.calls      | 0.18616      | Normal    | 0.051            | Normal    |
| Total.night.charge     | 0.46859      | Normal    | 0.736            | Normal    |
| Total.intl.minutes     | 0.00000      | No normal | $<0.001$         | No normal |
| Total.intl.calls       | 0.00000      | No normal | $<0.001$         | No normal |
| Total.intl.charge      | 0.00000      | No normal | $<0.001$         | No normal |
| Customer.service.calls | 0.00000      | No normal | $<0.001$         | No normal |

El conjunto de datos presenta normalidad parcial: las variables de uso cotidiano son normales, pero las de interacción y servicio muestran distribuciones sesgadas.

Esto sugiere que el comportamiento del cliente tiene una parte regular (uso del servicio) y otra irregular (interacciones excepcionales)

## 4. Análisis de Factores y Componentes principales

Por la baja correlación, tanto el PCA Y el Análisis de factores, resultarían poco útiles para este caso en particular. Por lo que solo realizaremos una breve explicación de ambos.

## 4.1. PCA

Tabla 4: Importancia de los componentes principales

| Componente | Varianza Explicada | Varianza Acumulada |
|------------|--------------------|--------------------|
| PC1        | 0.1673             | 0.1673             |
| PC2        | 0.0895             | 0.2567             |
| PC3        | 0.0891             | 0.3459             |
| PC4        | 0.0853             | 0.4312             |
| PC5        | 0.0836             | 0.5148             |
| PC6        | 0.0830             | 0.5979             |
| PC7        | 0.0820             | 0.6798             |
| PC8        | 0.0812             | 0.7610             |
| PC9        | 0.0808             | 0.8418             |
| PC10       | 0.0794             | 0.9212             |
| PC11       | 0.0788             | 1.0000             |
| PC12       | 0.0000             | 1.0000             |

Al realizar el PCA notamos que la varianza explicada con cada componente era menor al 20 %, esto sucede por la baja correlación entre las variables reduciendo solo en 3 dimensiones, y en realidad como la correlación entre los minuto y el cargo es de 1, podríamos desde el inicio descartar 3 de variables.




Figura 3: PCA

## 4.2. Análisis de Factores

El análisis de factores revela lo mismo que el PCA, Las variables de minutos y cargos se agrupan naturalmente, debido su alta correlación. Las demás variables no

---

cargan fuertemente en estos factores, lo que sugiere que representan dimensiones independientes del consumo.




Figura 4: Análisis de Factores

Se identifican tres factores principales:

- ML1: Uso diurno (minutos y cargos del día).
- ML2: Uso vespertino (minutos y cargos de la tarde).
- ML3: Uso nocturno (minutos y cargos de la noche).

## 5. Análisis de Correspondencias

El MCA se aplicó para explorar las relaciones entre variables categóricas del dataset:

- State (estado del cliente)
- Area.code (código de área)
- International.plan (plan internacional)
- Voice.mail.plan (plan de buzón de voz)
- Churn (abandono del cliente)

---

El propósito fue identificar asociaciones entre categorías y su relación con la cancelación del servicio.




Figura 5: MCA

En el mapa podemos observar lo siguiente:

- **International.plan = Yes** se ubica cerca de **Churn = True**, indicando una fuerte asociación entre tener plan internacional y la probabilidad de cancelar.
- **Voice.mail.plan = Yes** aparece próximo a **Churn = False**, lo que sugiere que contar con buzón de voz está relacionado con la permanencia.
- Los códigos de área 408, 415 y 510 se distribuyen en torno a las dimensiones, sin mostrar una asociación clara con churn, pero sí con la presencia o ausencia de planes.
- Los estados se dispersan en el espacio, reflejando que la localización geográfica no es un factor determinante en el abandono.

El MCA revela que las características de los planes (llamadas internacionales y buzón de voz ) son mas importantes para explicar el abandono que la ubicación geográfica.

## 6. Modelos Predictivos

Usamos 2 enfoque diferentes en esta sección:

- Regresión Logística
- k-Nearest Neighbors (kNN)

Ademas Clustering para describir **cómo son los clientes que abandonan**, lo que aporta contexto para interpretar las predicciones.

## 6.1. Clustering

La base de datos no posee una variable que indique razón de cancelación y podría ser que en zonas distintas podría haber problemas distintos del servicio.

Clustering sobre el grupo que canceló:




Figura 6

El método AGNES WARD euclidean identificó 3 grupos de 138 185 y 65





Figura 7

No parece haber sido una buena clasificación, cada silhouette fue muy bajo; el número de clusters pudo ser incorrecto puesto que todos tuvieron un número bajo, quizá debido a la homogeneidad de los datos (todos cancelan) sea mejor considerar menos grupos

### Silhouette - AGNES k=2

n = 388

2 clusters  $C_j$   
 $j : n_j \mid \text{ave}_{i \in C_j} s_i$



Average silhouette width : 0.2


Figura 8

Hubo mejora pero no mucha, los clusters siguen un poco difusos. Si hubiese al menos una partición el mejor modelo es de 2 grupos, por tanto se tiene:

Los grupos son de tamaños 323 y 65.

Los dos grupos tienen una cantidad de llamadas a servicio al cliente muy similares, las principales diferencias son que el grupo 2 contrata y usa más los servicios adicionales, no hay diferencias notorias en cantidad de quejas por lo que podría ser un fallo general en todos los servicios.

## 6.2. Regresión Logística



El modelo identificó varias variables significativas:

- International.planYes (OR  $\approx 8.15$ ,  $p < 0.001$ ): Los clientes con plan internacional tienen una probabilidad mucho mayor de cancelar.
- Voice.mail.planYes (OR  $\approx 0.13$ ,  $p < 0.01$ ): Los clientes con buzón de voz presentan menor riesgo de abandono.
- Customer.service.calls (OR  $\approx 1.66$ ,  $p < 0.001$ ): Un mayor número de llamadas al servicio se asocia con mayor probabilidad de churn.
- Total.day.minutes, Total.eve.minutes y Total.intl.minutes: El incremento en el uso de minutos está relacionado con mayor riesgo de abandono, aunque con efectos más moderados.
- Total.intl.calls (OR  $\approx 0.88$ ,  $p < 0.001$ ): Curiosamente, un mayor número de llamadas internacionales reduce el riesgo, lo que sugiere que el problema está más en la contratación del plan que en el uso efectivo




Figura 9: Curva ROC

El área bajo la curva ( $AUC = 0.826$ ) indica que el modelo tiene buena capacidad para distinguir entre clientes que abandonan y los que permanecen.

Después de aplicar el modelo obtuvimos los siguientes resultados:

Tabla 5: Matriz de confusión del modelo

| Prediction | False (Real) | True (Real) |
|------------|--------------|-------------|
| False      | 434          | 23          |
| True       | 138          | 72          |

Observamos que:

- 434 → Verdaderos negativos (no churn correctamente clasificados).
- 23 → Falsos negativos (clientes que sí abandonaron, pero el modelo los predijo como no churn).
- 138 → Falsos positivos (clientes que no abandonaron, pero el modelo los predijo como churn).
- 72 → Verdaderos positivos (churn correctamente clasificados).

Al Evaluar el modelo obtuvimos los siguientes resultados:

- Precisión global: 75.8 %
- Sensibilidad: 0.76 (capacidad para detectar clientes que abandonan).

- Especificidad: 0.76 (capacidad para identificar clientes que permanecen).
- AUC (Área bajo la curva ROC): 0.826, lo que indica un buen poder discriminante.

### 6.3. k-Nearest Neighbors (kNN)

El algoritmo k-Nearest Neighbors (kNN) se aplicó como modelo supervisado para clasificar clientes según su probabilidad de abandono (churn). Su principio se basa en la similitud entre observaciones: un cliente nuevo se clasifica según las categorías de sus k vecinos más cercanos en el conjunto de entrenamiento.



Este gráfico muestra cómo varían las métricas de desempeño del modelo kNN (precisión, sensibilidad y especificidad) conforme cambia el número de vecinos k. Se estableció  $k = 5$  como número de vecinos, buscando un equilibrio entre sensibilidad y estabilidad del modelo.

Después de aplicar el modelo obtuvimos los siguientes resultados:

Tabla 6: Matriz de confusión del modelo kNN

| Prediction | False (Real) | True (Real) |
|------------|--------------|-------------|
| False      | 529          | 60          |
| True       | 43           | 35          |

En esta tabla podemos ver que:

- $529 \rightarrow$  Verdaderos negativos (clientes correctamente clasificados como no churn).

- 60 → Falsos negativos (clientes que sí abandonaron, pero el modelo los predijo como no churn).
- 43 → Falsos positivos (clientes que no abandonaron, pero el modelo los predijo como churn).
- 35 → Verdaderos positivos (clientes correctamente clasificados como churn).

Al Evaluar el modelo obtuvimos los siguientes resultados:

- Precisión global: 84.56 %
- Sensibilidad: 0.36 (capacidad para detectar clientes que abandonan).
- Especificidad: 0.98 (capacidad para identificar clientes que permanecen)

## 6.4. Comparación de lo Modelos

La siguiente tabla esta un resumen de ambos modelos, para su comparación.

Tabla 7: Comparación de desempeño entre Regresión Logística y kNN

| Métrica           | Regresión Logística | kNN (k=5) |
|-------------------|---------------------|-----------|
| Precisión global  | 0.759               | 0.8996    |
| Sensibilidad      | 0.758               | 0.3684    |
| Especificidad     | 0.758               | 0.9878    |
| AUC (ROC)         | 0.826               | —         |
| Balanced Accuracy | 0.758               | 0.6781    |

### Regresión logística:

- Ofrece un equilibrio sólido entre sensibilidad y especificidad ( $\approx 0.76$  en ambos casos).
- Permite interpretar los factores de riesgo mediante coeficientes y odds ratios.
- Identifica claramente variables críticas: plan internacional, llamadas al servicio y buzón de voz.
- $AUC = 0.826$  confirma buen poder discriminante.

### kNN:

- Logra alta precisión global ( $\approx 90\%$ ), pero con sensibilidad baja ( $\approx 0.36$ ).

- 
- Clasifica muy bien los clientes que permanecen (especificidad  $\approx 0.99$ ), pero detecta menos casos de churn.
  - Es un modelo simple y eficaz, aunque menos explicativo.
  - Su desempeño depende del valor de  $k$  y de la correcta normalización de los datos.

En conclusión: La regresión logística es más adecuada cuando se busca interpretación y balance entre detectar clientes que abandonan y los que permanecen. El kNN es útil para lograr alta precisión global, pero su baja sensibilidad limita su capacidad para anticipar churn.